Adrian Kowal - 36378
Jakub Więcek - 36417

1. Zadanie i dane

- **Zadanie:** klasyfikacja nagrania 5s do jednej z 50 klas dźwięków
- **Zbiór:** ESC-50 (2000 nagrań WAV, 5s, mono, 50 klas × 40 nagrań).
- **Podział (oficjalne foldy):** foldy 1-3 → trening (1200), fold 4 → walidacja (400), fold 5 → test (400).
- **Wspólne przetwarzanie:** przepróbkowanie z 44,1 kHz do **16 kHz** dla obu modeli, więc 5s = **80 000 próbek**. Oba modele dostają tę samą informację, a porównanie jest uczciwe.
- **Batch:** 32 nagrania.

2. Kształty tensorów wejściowych i wyjściowych

	Model 1: CNN 2D	**Model 2: 1D-CNN + GRU**
Wejście	spektrogram **[32, 1, 128, 501]**	surowy sygnał **[32, 1, 80000]**
Znaczenie wymiarów	[batch, kanał, pasma mel, ramki czasu]	[batch, kanał, próbki]
Wyjście (logity)	**[32, 50]**	**[32, 50]**
Etykiety	[32], liczby całkowite 0–49	[32], liczby całkowite 0–49

Parametry spektrogramu: n_fft = 1024 (okno 64 ms), hop = 160 próbek (10 ms), 128 pasm mel. Daje to 80 000 / 160 + 1 = 501 ramek czasu. Wartości spektrogramu w skali logarytmicznej (dB), normalizowane średnią i odchyleniem ze zbioru treningowego.

Wyjście to 50 logitów na nagranie. Funkcja softmax zamienia je na prawdopodobieństwa klas.

Adrian Kowal - 36378
Jakub Więcek - 36417

3. Proponowane architektury

Obie sieci są **projektami własnymi** o zbliżonej liczbie parametrów (ok. 0,4 mln).

Model 1: CNN 2D w stylu VGG (wzorowane na prostych CNN dla ESC-50)

Warstwa	Kształt wyjścia
Wejście	[32, 1, 128, 501]
Blok 1: Conv2d 3×3 (32) → BatchNorm → ReLU → MaxPool 2×2	[32, 32, 64, 250]
Blok 2: Conv2d 3×3 (64) → BatchNorm → ReLU → MaxPool 2×2	[32, 64, 32, 125]
Blok 3: Conv2d 3×3 (128) → BatchNorm → ReLU → MaxPool 2×2	[32, 128, 16, 62]
Blok 4: Conv2d 3×3 (256) → BatchNorm → ReLU → MaxPool 2×2	[32, 256, 8, 31]
Global Average Pooling	[32, 256]
Dropout (0,3) → Linear	[32, 50]

Liczba parametrów: około **402 tys.**

Adrian Kowal - 36378
Jakub Więcek - 36417

Model 2: 1D-CNN + GRU (CRNN na surowym sygnale)

Warstwa	Kształt wyjścia
Wejście	[32, 1, 80000]
Blok 1: Conv1d k=11, stride 5 (64) → BatchNorm → ReLU → MaxPool 4	[32, 64, 4000]
Blok 2: Conv1d k=3 (128) → BatchNorm → ReLU → MaxPool 4	[32, 128, 1000]
Blok 3: Conv1d k=3 (128) → BatchNorm → ReLU → MaxPool 4	[32, 128, 250]
Zamiana osi na sekwencję	[32, 250, 128]: 250 kroków po 20 ms
GRU dwukierunkowy, 2 warstwy, 96 jednostek	[32, 250, 192]
Średnia po czasie	[32, 192]
Dropout (0,3) → Linear	[32, 50]

Liczba parametrów: około **382 tys.**

Konwolucje 1D skracają sekwencję z 80 000 próbek do 250 kroków. GRU bezpośrednio na 80 000 krokach uczyłby się zbyt wolno i niestabilnie.

4. Strategia uczenia

Uczenie od zera (from scratch) dla obu modeli. Uzasadnienie:

1. Celem projektu jest porównanie dwóch architektur. Uczciwe porównanie wymaga, by obie startowały z tego samego punktu (losowe wagi).
2. Wyniki są porównywalne z literaturą dla modeli trenowanych tylko na ESC-50: prosta CNN 64,5%, sieci na surowym sygnale 51,1–68,5%, człowiek 81,3%.

Mały zbiór (40 nagrań na klasę) grozi przeuczeniem. Przeciwdziałamy mu tak:

- **augmentacja:** szum, przesunięcie w czasie i zmiana głośności dla obu modeli, SpecAugment dla CNN;
- **regularyzacja:** dropout i weight decay;
- **Early Stopping** na stracie walidacyjnej.

Ustawienia treningu, wspólne dla obu modeli:

- optymalizator AdamW;
- rozgrzewka learning rate (warmup) przez pierwsze epoki, potem jego stopniowe obniżanie;
- maksymalnie ok. 100 epok, z zapisem najlepszych wag według walidacji.

5. Funkcja straty i metryki

- **Funkcja straty:** CrossEntropyLoss, standard dla klasyfikacji z jedną etykietą spośród wielu klas. Ta sama dla obu modeli.
- **Metryki jakości (fold 5, test):**
    - accuracy,
    - Precision, Recall i F1 (uśrednianie macro, zbiór jest zbalansowany),
    - macierz pomyłek 50×50,
    - krzywe ROC i PR w schemacie jeden-kontra-reszta (AUC macro).
- **Diagnostyka treningu:** krzywe straty i accuracy dla treningu i walidacji, ocena przeuczenia.
- **Koszt obliczeniowy:** liczba parametrów, czas epoki, czas predykcji na nagranie i na batch, zużycie pamięci GPU.
- **Wyjaśnialność:** Grad-CAM dla CNN oraz Integrated Gradients dla GRU.