Akademia Tarnowska
Wydział Nauk Technicznych
Katedra Informatyki
Dr inż. Marcin Skobel

2026

Sieci neuronowe i uczenie głębokie: Projekt
Zajęcia projektowe 1: Wybór tematu projektu i pozyskiwanie danych

Streszczenie

Celem pierwszych zajęć jest zidentyfikowanie problemu badawczego oraz wybór odpowiedniego zbioru danych. Wybór tematu determinuje potencjalne zaawansowanie projektu oraz zakres prac analitycznych.

1 Przegląd repozytoriów danych

Poniższa tabela przedstawia główne źródła, z których można pozyskać dane do swoich projektów:

Repozytorium	Charakterystyka	Dominujący typ danych
Kaggle	Konkursy i zbiory społeczności.	Tabele (CSV), Obrazy
UCI Machine Learning	Klasyczne zbiory akademickie.	Tabele (czyste)
Google Dataset Search	Agregator metadanych z sieci.	Różnorodne (mieszane)
Dane.gov.pl	Oficjalne statystyki państwowe.	Tabele, JSON, API
Hugging Face	Modele i zbiory do uczenia głębokiego.	Tekst (NLP), Audio

2 Jak wybrać właściwy temat?

Wybierając temat, należy kierować się trzema kryteriami:

1. **Kompletność danych:** Unikaj zbiorów niekompletnych, niezbalansowanych. Naprawa takich danych jest czasochłonna.
2. **Jasność celu:** Musisz wiedzieć, co chcesz przewidzieć.
   - *Klasyfikacja:* przypisanie do kategorii (np. chory / zdrowy).
   - *Segmentacja obrazu:* wyznaczenie zakresu obiektów do segmentacjni na obrazach
3. **Dostępność metryk:** Sprawdź, czy wiesz, jak ocenić swój model (np. czy masz kolumnę z ”prawdą”, do której się porównasz).

3 Techniki pozyskiwania danych

W zależności od wybranej oceny docelowej, dane można pozyskać na trzy sposoby:

Pobieranie statyczne (Static Datasets): Pobranie gotowych, standaryzowanych zbiorów danych uczenia głębokiego (np. z *Hugging Face Hub*, *Kaggle*, *TorchVision* czy *TensorFlow Datasets*). Najprostsza metoda gwarantująca spójność etykiet oraz powtarzalność eksperymentów.

API i strumieniowanie (Dynamic Data Streams): Pobieranie danych w czasie rzeczywistym lub w partiach poprzez interfejsy API (np. *Hugging Face Datasets API*, *OpenAI API*, serwery baz wektorowych). Pozwala na ciągłe zasilanie potoku danych (*data pipeline*) i świetnie integruje się z aplikacją GUI oraz modelem serwowanym na żywo.

Web Scraping i zbieranie danych masowych: Automatyczne pozyskiwanie niesstrukturyzowanych danych ze stron WWW (np. obrazów, tekstów) przy użyciu narzędzi takich jak *BeautifulSoup*, *Scrapy* czy *Selenium*. Wymaga rozbudowanego etapu czyszczenia, annotacji/etykietowania oraz filtracji danych przed wprowadzeniem ich do sieci neuronowej.

4 Zadanie na dziś: Karta Projektu

Do końca zajęć proszę o przygotowanie krótkiej notatki zawierającej:

- Tytuł roboczy projektu.
- Link do źródła danych.
- Plan listy zadań do wykonania w projekcie.
- Krótki opis: co ma robić model?