Akademia Tarnowska
Wydział Nauk Technicznych
Katedra Informatyki
Dr inż. Marcin Skobel

Sieci neuronowe i uczenie głębokie: Projekt
Zajęcia projektowe 2: Analiza danych i dobór architektury

Streszczenie

Celem drugich zajęć jest szczegółowa analiza struktury pozyskanych danych oraz wybór właściwej architektury sieci głębokiej (Deep Learning). Poprawny dobór modelu do charakteru danych – ustrukturyzowanych, przestrzennych, sekwencyjnych, grafowych lub zadań generowania treści (obrazy, dźwięk, tekst) – stanowi kluczowy warunek sukcesu projektu.

1 Dopasowanie architektury do typu danych i zadania

Poniższa tabela przedstawia zestawienie głównych modalności danych oraz typów zadań wraz z rekomendowanymi rodzinami sieci neuronowych:

Typ danych / Zadanie	**Rekomendowana architektura**	**Kluczowe mechanizmy / warstwy**
Tabele (CSV, SQL)	MLP, TabNet, ResNet-Tabular	Warstwy gęste (Dense), BatchNorm, Dropout
Obrazy i Wideo (Analiza)	CNN (ResNet, EfficientNet), ViT	Konwolucja 2D/3D, Pooling, Self-Attention
Audio i Sygnały	RNN, LSTM, GRU, 1D-CNN, ViT	Rekurencja, Atencja 1D, Sploty 1D
Tekst i Sekwencje	Transformery (BERT, GPT, LLM)	Multi-Head Self-Attention, Positional Encoding
Grafy i Cząsteczki	GNN (GCN, GAT, MPNN)	Agregacja węzłów, Przekazywanie wiadomości
Generowanie obrazów/treści	Diffusion (UNet/DiT), GAN, VAE	Denoising, Latent Space, Adversarial Loss

2 Jak wybrać właściwą architekturę?

Przy doborze sieci dla swojego projektu należy uwzględnić trzy kluczowe kryteria:

1. **Indukcyjne obciążenie modelu (Inductive Bias):** Dopasuj warstwy do geometrii i specyfiki zadania.
   - *Niezmienniczość na translację:* wybierz warstwy splotowe (CNN) dla analizy obrazów.
   - *Zależności czasowe / sekwencyjne:* wybierz mechanizmy rekurencyjne lub atencję (Transformers) dla audio i tekstu.

- *Generowanie i synteza treści:* wybierz modele dyfuzyjne (Diffusion Models / DiT), GAN-y lub autoenkodery (VAE) dla odszumiania, próbkowania ze przestrzeni ukrytej (*latent space*) lub syntezy multimodalnej (np. tekst-na-obraz).

2. **Rozmiar zbioru a transfer wiedzy (Transfer Learning):** Dla małych i średnich zbiorów danych (oraz złożonych zadań generatywnych) zaleca się stosowanie modeli wstępnie wytrenowanych (*backbone / pretrained checkpoint*) i ich dostrajanie (*fine-tuning*, LoRA, ControlNet).

3. **Złożoność obliczeniowa i rozmiar tensora:** Upewnij się, że rozmiar wejściowego/wyjściowego tensora (np. $[B, C, H, W]$ dla obrazu lub $[B, C, H, W]$ w krokach czasowych t dla dyfuzji) mieści się w pamięci GPU podczas uczenia.

3 Przegląd głównych rodzin sieci głębokich

W zależności od wybranego problemu projektowego, architektura sieci będzie opierać się na jednym z poniższych paradygmatów:

Sieci Gęste (MLP – Multi-Layer Perceptron): Podstawowa architektura przeznaczona dla ustrukturyzowanych danych tabelarycznych (pliki CSV). Przetwarza wektory cech o stałej długości.

Sieci Splotowe (CNN – Convolutional Neural Networks): Zoptymalizowane pod kątem dwu- i trójwymiarowych danych przestrzennych (obrazy, skany medyczne CT/MRI, klatki wideo). Wykorzystują filtry konwolucyjne do wyciągania cech lokalnych.

Sieci Rekurencyjne (RNN / LSTM / GRU) i Sploty 1D: Przeznaczone do szeregów czasowych, odczytów z czujników IoT oraz sygnałów audio. Pozwalają na wychwytywanie dynamiki czasowej.

Transformery (Self-Attention, ViT, LLM): Architektura oparta na mechanizmie uwagi, dominująca w NLP, nowoczesnej wizji komputerowej (ViT) oraz generowaniu i tłumaczeniu sekwencji.

Sieci Grafowe (GNN – Graph Neural Networks): Dedykowane dla danych o niestrukturalnej geometrii, takich jak cząsteczki chemiczne, struktury białek czy sieci połączeń.

Modele Generatywne (Diffusion, GAN, VAE, DiT): Dedykowane do syntezy i generowania nowych danych (obrazy, audio, obiekty 3D, tekst-na-obraz). Modele dyfuzyjne (Diffusion/DiT) bazują na procesie odszumiania, GAN-y na współzawodnictwie generatora i dyskryminatora, a VAE na próbkowaniu z ciągłej przestrzeni ukrytej.

4 Zadanie na dziś: Specyfikacja Architektury Projektu

Do końca zajęć proszę o przygotowanie notatki technicznej określającej:

- **Kształt tensora wejściowego i wyjściowego** (np. $[16, 3, 224, 224]$ dla klasyfikacji obrazów lub $[16, 4, 64, 64]$ dla dyfuzji w przestrzeni ukrytej).

- **Proponowana architektura sieci** (nazwa modelu bazowego, np. `ResNet-18`, `Stable Diffusion / UNet`, `DiT`, `LSTM`, `GCN`).
- **Strategia uczenia:** Uczenie od zera (*from scratch*), dostrajanie (*Fine-tuning*), czy adaptacja niskowymiarowa (*LoRA / ControlNet*).
- **Określenie funkcji straty (Loss Function) oraz metryk oceny:**
  - *Klasyfikacja / Analiza:* `CrossEntropyLoss`, `BCEWithLogitsLoss`.
  - *Regresja / Rekonstrukcja:* `MSELoss`, `L1Loss`, `Perceptual Loss (LPIPS)`.
  - *Generowanie treści:* Loss dyfuzyjny (*Noise Prediction MSE*), *Adversarial Loss* (GAN), *ELBO* (VAE) oraz metryki jakości generatów (np. FID, IS, SSIM).