Adrian Kowal - 36378
Jakub Więcek - 36417

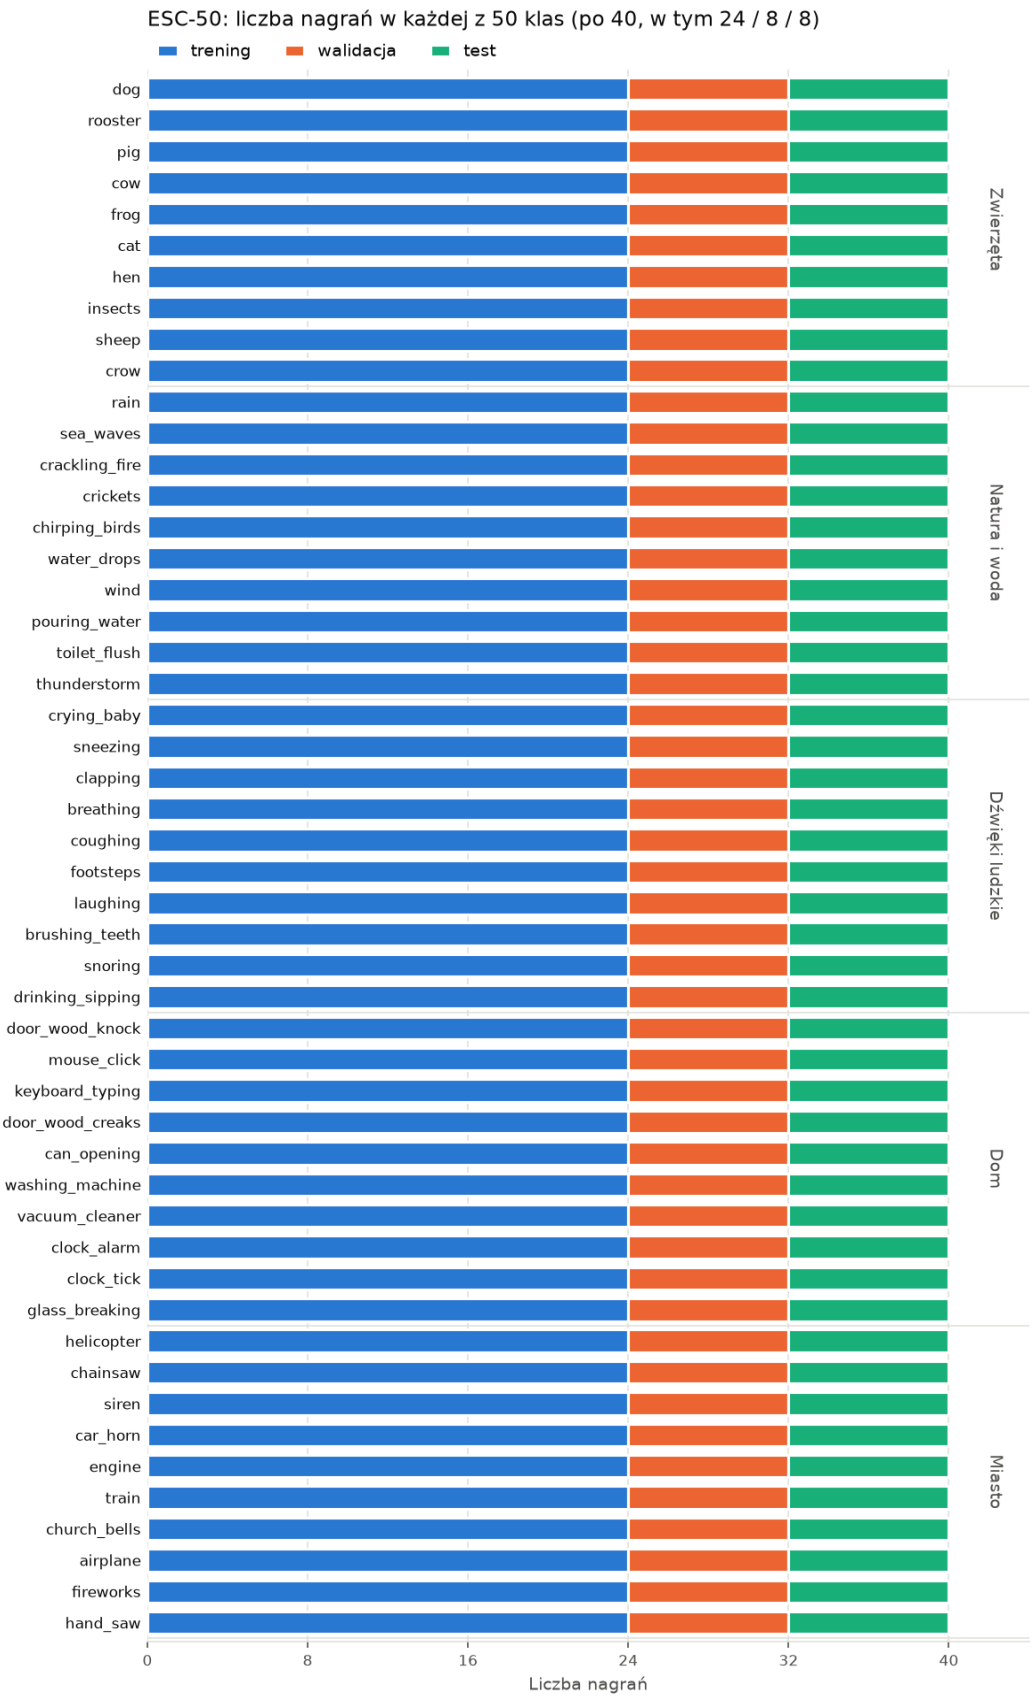
# 1. Opis zbioru danych

| | |
|---|---|
| Modalność | dźwięk (krótkie nagrania) |
| Źródło | ESC-50, https://github.com/karolpiczak/ESC-50 |
| Liczba próbek | 2000 nagrań |
| Klasy | 50 klas (np. pies, deszcz, syrena) w 5 grupach |
| Jedna próbka | 5 s, 44,1 kHz, mono, czyli 220 500 liczb |
| Po przetworzeniu | 16 kHz, czyli 80 000 liczb |
| Wejście modelu CNN | spektrogram [32, 1, 128, 501] (batch, kanał, pasma częstotliwości, chwile czasu) |
| Wejście modelu GRU | surowy sygnał [32, 1, 80000] (batch, kanał, próbki) |
| Wyjście | [32, 50], czyli 50 wyników, po jednym na klasę |

Oba modele mają po ok. 0,4 mln parametrów i w treningu zajmą mniej niż 2 GB

Adrian Kowal - 36378
Jakub Więcek - 36417

# 2. Rozkład etykiet



| Grupa | Klasy | Nagrań na klasę | Razem |
|---|---|---|---|
| Zwierzęta | dog, rooster, pig, cow, frog, cat, hen, insects, sheep, crow | 40 | 400 |
| Natura i woda | rain, sea_waves, crackling_fire, crickets, chirping_birds, water_drops, wind, pouring_water, toilet_flush, thunderstorm | 40 | 400 |
| Dźwięki ludzkie | crying_baby, sneezing, clapping, breathing, coughing, footsteps, laughing, brushing_teeth, snoring, drinking_sipping | 40 | 400 |
| Dom | door_wood_knock, mouse_click, keyboard_typing, door_wood_creaks, can_opening, washing_machine, vacuum_cleaner, clock_alarm, clock_tick, glass_breaking | 40 | 400 |
| Miasto | helicopter, chainsaw, siren, car_horn, engine, train, church_bells, airplane, fireworks, hand_saw | 40 | 400 |

Na każdą klasę przypada 24 nagrania treningowe, 8 walidacyjnych i 8 testowych.

**Wniosek:** zbiór jest **idealnie zrównoważony**. Każda klasa ma 40 nagrań, czyli 2% zbioru, więc nie ma klas dominujących ani rzadkich. Problemem jest za to **mała liczba przykładów** na klasę. Niektóre klasy brzmią podobnie i model może je mylić, np. kura i kogut, tykanie zegara i budzik albo deszcz i fale.

# 3. Jakość danych

| Co sprawdziliśmy | Jak | Wynik |
|---|---|---|
| Uszkodzone pliki | próba odczytu | 0 |
| Braki i błędne wartości | puste wartości (NaN), nieskończoności | 0 |
| Niezgodny format | częstotliwość, kanały, długość | 0, wszystkie są takie same |
| Duplikaty | porównanie sum kontrolnych (MD5) plików | 0 |
| Nagrania dopełnione ciszą | ciąg zer dłuższy niż 1 s | 334 |
| Przesterowane | próbki w maksimum głośności | 195 |

| | | |
|---|---|---|
| Prawie same cisze | ponad 90% nagrania to cisza | 14 |
| Nietypowe | algorytm Isolation Forest na cechach dźwięku (MFCC) | 142 |

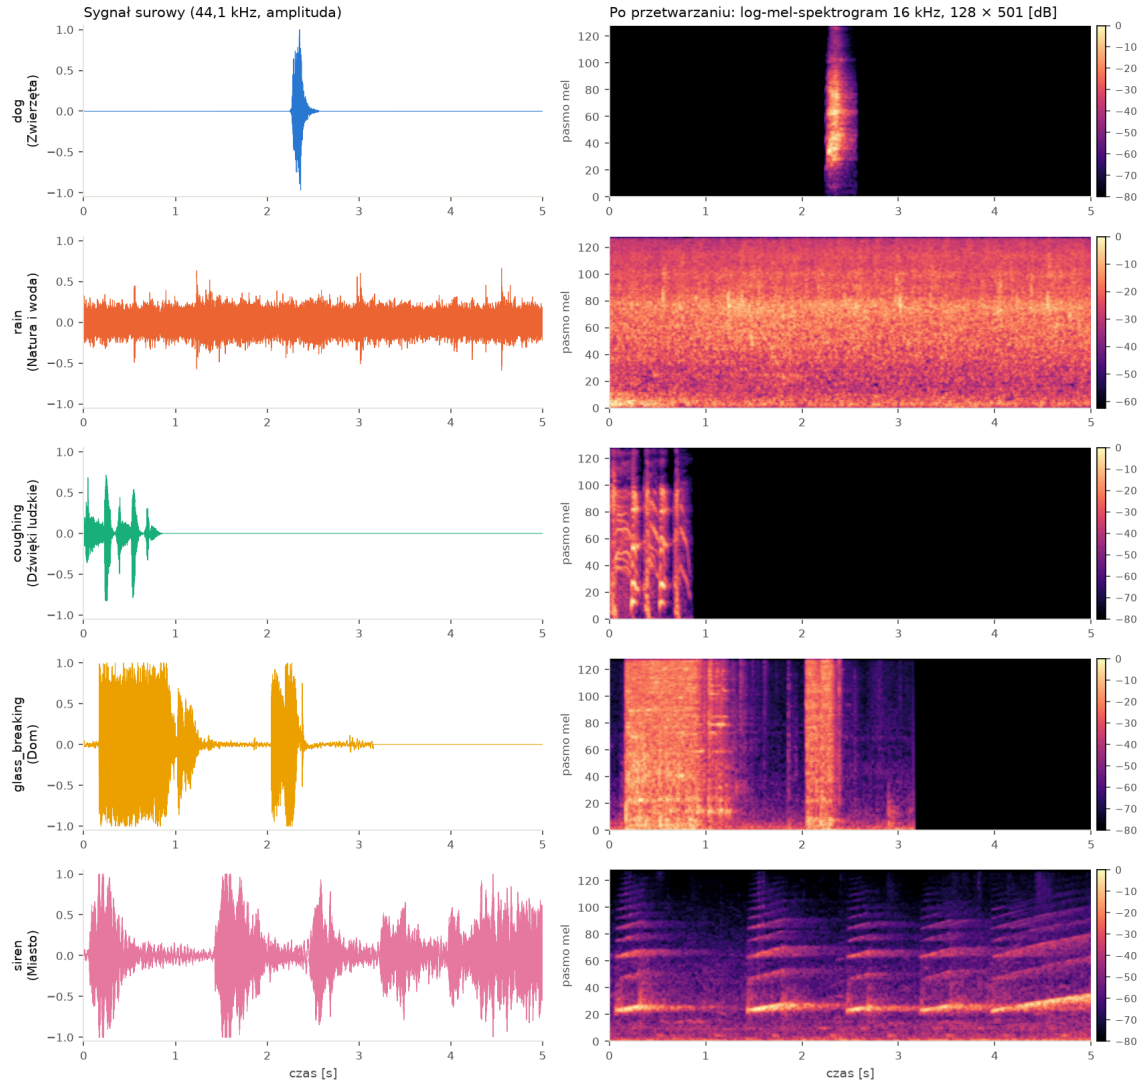
**Decyzje:**

- **Niczego nie usuwamy.** Dane są technicznie czyste.
- **Ciszę dopełniającą** autorzy dodali do krótkich dźwięków, np. tłuczonego szkła, żeby każde nagranie miało 5 s. Zależy ona od klasy, więc model mógłby się uczyć „ile jest ciszy” zamiast „jaki to dźwięk”. Przeciwdziałamy temu losowym przesuwaniem nagrań w czasie.
- **Przesterowanie i bardzo ciche nagrania** wynikają z różnej głośności nagrań źródłowych. Wyrównujemy je normalizacją głośności.
- **Nietypowe nagrania:** przesłuchaliśmy kilka najbardziej nietypowych (głośne syreny, ciche nagrania zwierząt). Wszystkie mają poprawną etykietę, więc zostają.
- **Fragmenty tego samego nagrania źródłowego** nigdy nie trafiają jednocześnie do treningu i testu.

Adrian Kowal - 36378
Jakub Więcek - 36417

# 4. Wizualizacja danych

### Próbki surowe i po przetworzeniu

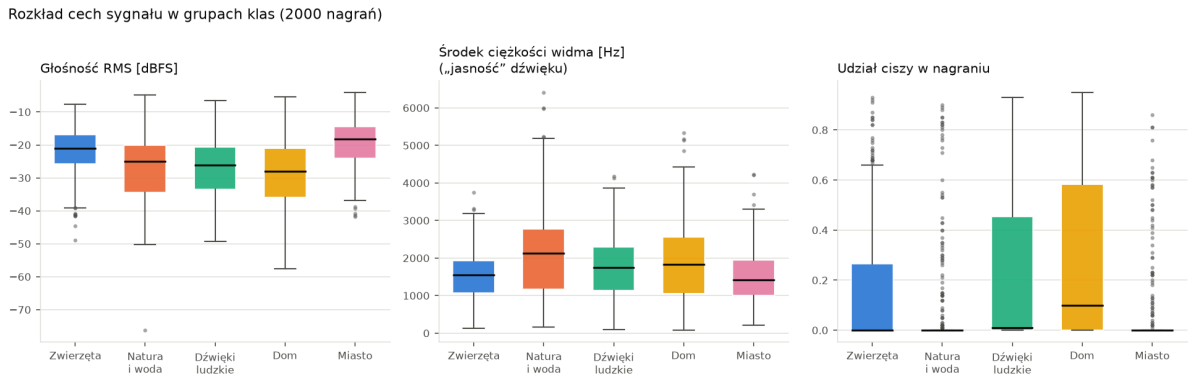



Lewa kolumna pokazuje surowy sygnał, a prawa spektrogram po przetworzeniu (to, co zobaczy model CNN). Widać, że:

- dźwięki różnią się kształtem: szczekanie i kaszel to krótkie impulsy, deszcz to ciągły szum, a syrena ma wyraźne, powtarzające się tony;
- zdarzenie może być w dowolnym miejscu nagrania (pies w środku, kaszel na początku), więc model musi rozpoznawać dźwięk niezależnie od jego położenia;
- dopełnienie ciszą widać jako czarne pole.

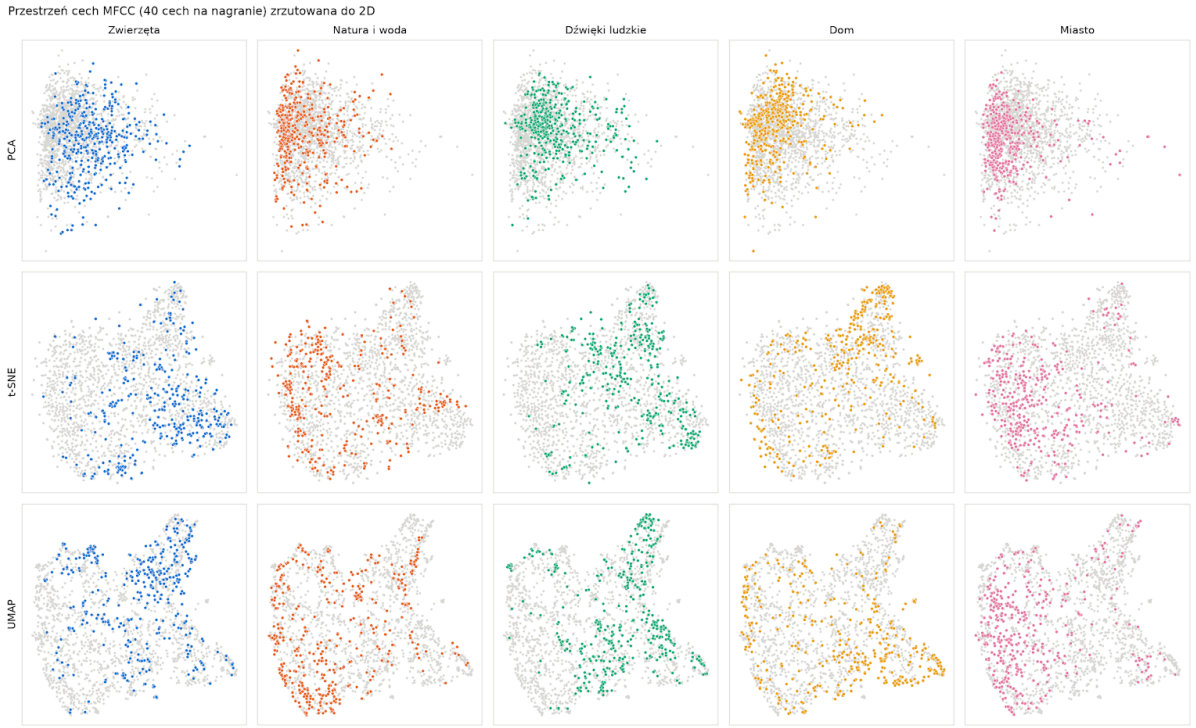
Adrian Kowal - 36378
Jakub Więcek - 36417

## Rozkład cech w grupach




- Głośność różni się między grupami nawet o 10 dB: Miasto jest najgłośniejsze, Dom najcichszy. Głośność zależy jednak od sposobu nagrania, więc model nie powinien się na niej opierać.
- Dźwięki natury (deszcz, wiatr) są najbardziej „jasne", czyli mają dużo wysokich tonów, a dźwięki miasta (silniki) najbardziej „ciemne".
- Cisza występuje głównie w grupie Dom, gdzie dźwięki są krótkie.

## Przestrzeń cech (PCA, t-SNE, UMAP)




Każde nagranie opisaliśmy 40 liczbami (cechy MFCC) i rzutowaliśmy na płaszczyznę 2D trzema metodami.

- **PCA:** wszystkie grupy są wymieszane.
- **t-SNE i UMAP:** grupy zajmują swoje obszary, ale mocno na siebie zachodzą.

**Wniosek:** proste cechy nie wystarczą do rozpoznania 50 klas. Potrzebna jest sieć neuronowa, która widzi, jak dźwięk zmienia się w czasie.

# 5. Strategia walidacji

- **Podczas pracy nad modelami** stosujemy pojedynczy podział (holdout) według oficjalnych foldów:

| Zbiór | Foldy | Udział |
|---|---|---|
| trening | 1–3 | 60% |
| walidacja | 4 | 20% |
| test | 5 | 20% |

- Jest szybki: jeden trening na eksperyment.

- **Na koniec** ostateczne wersje obu modeli sprawdzamy **walidacją krzyżową na 5 foldach**. Każdy fold raz jest testem, a wynik podajemy jako średnią ± odchylenie. Powody:

    - zbiór jest mały, więc wynik z jednego podziału może zależeć od przypadku;
    - wyniki w literaturze dla ESC-50 liczone są właśnie w ten sposób.

- **Liczba foldów (5)** wynika z podziału przygotowanego przez autorów zbioru.

- **Podział grupowy:** tak. Oficjalne foldy trzymają fragmenty tego samego nagrania razem, więc model nie zobaczy w teście „kawałka” nagrania, które zna z treningu.

- **Stratyfikacja:** niepotrzebna, bo każdy fold ma już po 8 nagrań każdej klasy.

- **Podział chronologiczny:** nie dotyczy, bo nagrania są od siebie niezależne.

# 6. Ochrona przed przeciekiem danych

- **Normalizację spektrogramów** (średnia i odchylenie) liczymy tylko na zbiorze treningowym i stosujemy do walidacji i testu.
- **Głośność surowego sygnału** normalizujemy osobno w każdym nagraniu, więc nie korzystamy przy tym z innych danych.
- **Augmentację**, czyli losowe zmiany nagrań, stosujemy tylko w treningu.
- **Hiperparametry** i moment zatrzymania treningu wybieramy na walidacji.
- **Test** używamy raz, na samym końcu.
- W walidacji krzyżowej normalizację liczymy od nowa w każdej rundzie.
- W EDA skaler cech i Isolation Forest dopasowaliśmy tylko do treningu.

# 7. Plan oceny modelu

| Metryka | Dlaczego |
|---|---|
| Accuracy (odsetek trafień) | klasy są zrównoważone, więc jest miarodajna; tej metryki używa literatura |
| Precision, Recall, F1 (średnia ze wszystkich klas) | pokazują, które klasy model rozpoznaje słabo |
| Macierz pomyłek | pokazuje, które klasy model ze sobą myli |
| Krzywe ROC i PR | oceniają, jak pewne są przewidywania |
| Krzywe uczenia (trening vs walidacja) | wykrywają przeuczenie |
| Czas treningu i predykcji, liczba parametrów | porównanie kosztu obu modeli |

Punkt odniesienia z literatury: prosta CNN osiąga 64,5%, sieci na surowym sygnale 51–69%, a człowiek 81%.

# 8. Wnioski dla projektu

1. **Funkcja straty:** zwykła CrossEntropyLoss, bez wag klas, bo klasy są zrównoważone.

2. **Mało danych** to ryzyko przeuczenia. Odpowiadamy na nie:

    - augmentacją,
    - dropoutem,
    - wczesnym zatrzymaniem treningu (Early Stopping),
    - małymi modelami.

3. **Augmentacja wynika z EDA:**
    - przesunięcie w czasie, bo zdarzenia leżą w różnych miejscach i występuje cisza dopełniająca;
    - zmiana głośności, bo grupy różnią się głośnością;
    - dodanie szumu;
    - dla CNN zasłanianie fragmentów spektrogramu (SpecAugment).
4. Nie odwracamy nagrań w czasie, bo zmieniłoby to charakter dźwięku.

5. **Architektura:** dźwięki różnią się wzorcami w czasie i częstotliwości, a proste cechy ich nie rozdzielają. Dlatego wybraliśmy CNN na spektrogramie i 1D-CNN + GRU na sygnale.

6. **Ocena:** podział grupowy po oficjalnych foldach, końcowa walidacja krzyżowa i analiza wyjaśnialności (XAI). W XAI sprawdzimy, czy model nie „patrzy” na ciszę zamiast na sam dźwięk.