Akademia Tarnowska
Wydział Nauk Technicznych
Katedra Informatyki
Dr inż. Marcin Skobel

2026

AKADEMIA TARNOWSKA

Sieci neuronowe i uczenie głębokie: Projekt
Zajęcia projektowe 3: Wybór techniki walidacji oraz pogłębiona analiza eksploracyjna danych

Streszczenie

Celem zajęć jest poznanie metod walidacji modeli uczenia głębokiego (Deep Learning) oraz przeprowadzenie pogłębionej analizy eksploracyjnej danych (Exploratory Data Analysis, EDA). Poprawny podział danych na zbiór treningowy, walidacyjny i testowy oraz rozpoznanie struktury, rozkładu etykiet, wymiarowości i jakości próbek stanowią podstawę rzetelnej oceny modelu. Zagadnienia zostaną omówione dla różnych modalności: obrazów, dźwięku, tekstu, szeregów czasowych, danych tabelarycznych, wideo i danych wykorzystywanych w zadaniach generatywnych.

1 Wybór techniki walidacji modelu

Celem walidacji jest oszacowanie, jak dobrze wytrenowany model będzie działał na danych, których nie widział podczas uczenia. W uczeniu głębokim właściwy podział danych jest szczególnie istotny ze względu na dużą liczbę parametrów modeli, możliwość przeuczenia oraz koszt obliczeniowy wielokrotnego trenowania sieci.

Należy rozróżnić trzy zbiory:

- **Zbiór treningowy (train)** – służy do aktualizacji parametrów sieci za pomocą algorytmu optymalizacji, np. SGD lub Adam.
- **Zbiór walidacyjny (validation)** – służy do wyboru hiperparametrów, architektury, progu decyzyjnego i epoki zakończenia uczenia, np. z wykorzystaniem mechanizmu *early stopping*.
- **Zbiór testowy (test)** – służy do końcowej, możliwie niezależnej oceny gotowego rozwiązania. Nie powinien być wykorzystywany do wielokrotnego dostrajania modelu.

1.1 Holdout – pojedynczy podział danych

Metoda *holdout* polega na jednorazowym podziale dostępnych danych na rozłączne podzbiory. Przykładowo:

$$D = D_{\text{train}} \cup D_{\text{val}} \cup D_{\text{test}}, \qquad D_i \cap D_j = \varnothing \quad \text{dla } i \neq j.$$

Typowe proporcje to:

- 80% danych do treningu i 20% do testowania;
- 70% do treningu, 15% do walidacji i 15% do testowania;
- 60% do treningu, 20% do walidacji i 20% do testowania.

Nie istnieje jedna uniwersalna proporcja. Podział należy dobrać do liczebności zbioru, złożoności problemu, liczby klas i sposobu pozyskiwania danych. W dużych zbiorach pojedynczy podział może być wystarczający, natomiast w małych zbiorach wynik może silnie zależeć od tego, które próbki trafiły do poszczególnych części.

1.2 Cross-validation – walidacja krzyżowa

W walidacji krzyżowej (*Cross-Validation, CV*) dane dzieli się na K części, czyli *foldów*. W każdej iteracji jedna część pełni funkcję walidacyjną, a pozostałe służą do treningu. W klasycznej walidacji K-krotnej każdy fold jest wykorzystany do walidacji dokładnie raz.

$$\widehat{M}_{CV} = \frac{1}{K} \sum_{k=1}^{K} M_k,$$

gdzie M_k oznacza wynik uzyskany w k-tej iteracji, np. accuracy, F1-score lub AUC.

Najczęściej stosuje się $K = 5$ albo $K = 10$. Większa liczba foldów oznacza więcej treningów, a więc wyższy koszt obliczeniowy. Wyniki poszczególnych iteracji pozwalają także ocenić zmienność jakości modelu.

1.3 Od czego zależy wybór metody?

Kryterium	**Holdout**	**Cross-validation**
Mały zbiór danych	Może dawać niestabilny wynik; część danych pozostaje poza treningiem.	Pozwala wielokrotnie wykorzystywać dane do treningu i walidacji.
Duży zbiór danych	Zwykle wystarcza do wiarygodnej oceny przy właściwym podziale.	Może być kosztowna, ponieważ wymaga wielu treningów.
Czas treningu	Zazwyczaj krótszy.	Rośnie w przybliżeniu proporcjonalnie do liczby foldów.
Stabilność oceny	Silniej zależy od konkretnego podziału.	Umożliwia analizę średniej i zmienności wyników.
Dostrajanie modelu	Wymaga wydzielonego zbioru walidacyjnego.	Pozwala porównywać konfiguracje na wielu podziałach, ale zwiększa koszt.

1.4 Dobór walidacji do struktury danych

- **Klasyfikacja z nierównymi klasami:** należy rozważyć podział stratyfikowany (*Stratified Holdout*, *StratifiedKFold*), który zachowuje proporcje klas. Każda część musi zawierać wystarczającą liczbę przykładów reprezentujących rzadkie klasy.
- **Wielokrotne próbki od tej samej osoby lub urządzenia:** należy stosować podział grupowy (*Group Holdout*, *GroupKFold*), jeżeli celem jest ocena generalizacji na nieznanych osobach lub urządzeniach. Próbki tej samej osoby nie powinny przypadkowo trafić jednocześnie do treningu i testu.

- **Szeregi czasowe i prognozowanie:** stosuje się walidację chronologiczną lub kroczącą (*Time Series Split*). Trening musi wykorzystywać wyłącznie informacje dostępne przed okresem walidacyjnym.

- **Obrazy, audio i wideo:** należy uwzględnić źródło próbek, np. osobę, sesję nagraniową, film lub miejsce wykonania. Podział pojedynczych klatek albo silnie podobnych fragmentów między train i test może prowadzić do zawyżonej oceny.

- **Modele generatywne:** zbiór testowy powinien obejmować niezależne przykłady, a ocena jakości generowania powinna być przeprowadzana na podstawie ustalonego protokołu. Należy unikać porównywania wygenerowanych próbek z przykładami treningowymi w sposób prowadzący do nieuprawnionych wniosków.

1.5 Ważna zasada: brak przecieku danych

Przeciek danych (*ang. Data leakage*) występuje wtedy, gdy do treningu lub podejmowania decyzji o modelu przedostaje się informacja, która nie powinna być dostępna na danym etapie. Przykładowo, skalowanie, imputacja braków, selekcja cech i redukcja wymiarowości powinny być dopasowywane wyłącznie na zbiorze treningowym danej iteracji. Następnie ten sam transformator stosuje się do walidacji i testu.

W przypadku walidacji krzyżowej wszystkie operacje zależne od danych, w tym oversampling, selekcja cech i normalizacja, muszą być wykonywane wewnątrz odpowiedniego foldu. Zbiór testowy powinien pozostać nietknięty aż do końcowej oceny.

2 Pogłębiona analiza eksploracyjna danych (EDA)

EDA nie ogranicza się do wyświetlenia kilku wykresów. Jej celem jest zrozumienie, jakie informacje zawierają dane, jakie problemy jakościowe występują oraz czy dostępne próbki pozwalają wiarygodnie trenować i oceniać planowaną architekturę sieci.

2.1 Analiza rozkładu etykiet

W pierwszej kolejności należy sprawdzić liczbę klas, ich liczebność oraz proporcje. W klasyfikacji warto wyznaczyć:

- liczbę przykładów w każdej klasie;

- udział procentowy każdej klasy;

- klasę dominującą i klasy rzadkie;

- liczbę przykładów dostępną w train, validation i test;

- możliwe błędy etykietowania oraz klasy semantycznie podobne.

Nierównowaga klas może prowadzić do pozornie wysokiej accuracy przy słabej jakości rozpoznawania klas rzadkich. Dlatego warto analizować także macierz pomyłek, precision, recall, F1-score oraz – gdy zadanie i sposób wyznaczania prawdopodobieństw na to pozwalają – ROC AUC lub PR AUC.

W zadaniach regresji należy sprawdzić rozkład wartości docelowej, zakres zmienności, wartości skrajne oraz ewentualne skupiska. W zadaniach generatywnych istotne jest również zbadanie różnorodności przykładów i ryzyka nadmiernej reprezentacji wybranych typów danych.

2.2 Analiza wymiarowości i kształtu danych

Kształt tensora wejściowego zależy od modalności danych i przyjętej architektury. Warto go sprawdzić jeszcze przed rozpoczęciem treningu.

Modalność	**Przykładowy kształt**	**Co sprawdzić?**
Dane tabelaryczne	$[N, F]$	Liczbę cech, typy zmiennych, skalę i braki danych.
Obrazy	$[B, C, H, W]$	Liczbę kanałów, rozdzielczość, proporcje obrazu i format pikseli.
Audio / sygnały	$[B, C, T]$ lub $[B, F, T]$	Częstotliwość próbkowania, długość, liczbę kanałów i ciszę.
Tekst	$[B, L]$ lub $[B, L, D]$	Długość sekwencji, tokenizację, padding i maski uwagi.
Wideo	$[B, T, C, H, W]$	Liczbę klatek, FPS, rozdzielczość i długość klipu.
Grafy	Liczba węzłów i krawędzi oraz cechy węzłów	Spójność grafu, stopnie węzłów i rozmiar grafów.

Symbole oznaczają: N – liczbę przykładów, B – rozmiar partii, F – liczbę cech, C – liczbę kanałów, H, W – wysokość i szerokość, T – liczbę kroków czasowych, L – długość sekwencji, a D – wymiar reprezentacji.

Należy także oszacować liczbę parametrów modelu, rozmiar pojedynczej próbki i zapotrzebowanie na pamięć GPU. Bardzo duża rozdzielczość obrazu, długie sekwencje albo duże partie mogą uniemożliwić trening nawet wtedy, gdy liczba samych przykładów nie jest duża.

2.3 Wizualizacja danych i przestrzeni cech

Przed treningiem warto obejrzeć próbki surowe oraz przykłady po wstępnym przetwarzaniu. W zależności od modalności można zastosować:

- **Obrazy:** siatki przykładowych obrazów, histogramy jasności, rozkłady kanałów, mapy masek segmentacyjnych.
- **Audio:** przebieg czasowy, spektrogram, spektrogram Mel oraz rozkład długości nagrań.
- **Tekst:** długości dokumentów, częstości tokenów, rozkłady etykiet i przykłady po tokenizacji.
- **Szeregi czasowe:** wykresy przebiegów, rozkłady wartości, autokorelację i analizę brakujących odcinków.

- **Wideo:** wybrane klatki, rozkład liczby klatek, rozdzielczości i długości nagrań.
- **Dane tabelaryczne:** histogramy, wykresy pudełkowe, macierze korelacji oraz rozkłady cech w podziale na klasy.

W celu wstępnego zbadania podobieństwa próbek można wykorzystać metody redukcji wymiarowości, takie jak PCA, t-SNE i UMAP. Pozwalają one przedstawić próbki w przestrzeni 2D lub 3D, co może ujawnić skupiska, próbki nietypowe i potencjalne nakładanie się klas.

- **PCA** – metoda liniowa, przydatna do badania głównych kierunków zmienności i wstępnej redukcji liczby cech.
- **t-SNE** – metoda nieliniowa, która dobrze eksponuje lokalne sąsiedztwa, lecz odległości między odległymi skupiskami nie powinny być interpretowane jako dokładna miara podobieństwa.
- **UMAP** – metoda nieliniowa, często używana do wizualizacji lokalnej struktury danych i potencjalnych skupisk.

Dla obrazów, audio i tekstu wizualizację można wykonywać na reprezentacjach wyekstrahowanych przez wstępnie wytrenowany model. Wtedy każda próbka jest reprezentowana przez wektor osadzenia (*embedding*). Trzeba pamiętać, że widoczny rozdział klas na wykresie 2D nie gwarantuje dobrej jakości klasyfikatora, a brak wyraźnych skupisk nie oznacza automatycznie, że zadanie jest nierozwiązywalne.

2.4 Identyfikacja próbek uszkodzonych i nietypowych

Błędy jakości danych mogą utrudniać uczenie bardziej niż niewłaściwy dobór architektury. Analiza powinna obejmować:

- **Braki danych:** wartości NaN, puste pliki, brakujące kanały i niekompletne sekwencje.
- **Niepoprawne wartości:** nieskończoności, wartości poza dopuszczalnym zakresem, błędne formaty i niezgodne typy.
- **Uszkodzone pliki:** obrazy, których nie da się odczytać, nagrania o zerowej długości, uszkodzone klatki wideo lub rekordy o niezgodnej strukturze.
- **Próbki nietypowe:** obserwacje o skrajnych wartościach, odmiennym rozkładzie sygnału, nietypowym embeddingu lub niezgodności z pozostałymi przykładami tej samej klasy.
- **Duplikaty i podobne próbki:** identyczne obrazy, powielone rekordy, nakładające się fragmenty sygnału albo klatki pochodzące z tego samego filmu.
- **Błędne etykiety:** próbki, których treść nie odpowiada przypisanej klasie lub adnotacji.

Do wykrywania obserwacji nietypowych można używać odległości od sąsiadów, metod opartych na gęstości, takich jak LOF, algorytmu Isolation Forest albo odległości w przestrzeni embeddingów. W przypadku obrazów, dźwięku i wideo nie należy ograniczać się wyłącznie do statystyk liczbowych – konieczna może być również inspekcja wizualna lub odsłuch.

Próbki nietypowej nie należy automatycznie usuwać. Może ona być błędem pomiaru, ale może również reprezentować ważny przypadek rzadki. Każde odrzucenie danych powinno mieć uzasadnienie, a reguły czyszczenia należy ustalać bez wykorzystywania informacji ze zbioru testowego.

3 EDA i walidacja w zadaniach głębokiego uczenia

Wyniki EDA wpływają na dalsze decyzje projektowe:

- **Nierównowaga klas** może uzasadniać ważenie funkcji straty, próbkowanie lub zmianę metryk oceny.
- **Mała liczba niezależnych przykładów** przemawia za ostrożną walidacją i rozważeniem transfer learningu.
- **Dane powiązane grupami** wymagają podziału według osób, urządzeń, sesji lub źródeł.
- **Dane czasowe** wymagają zachowania kolejności chronologicznej.
- **Duża liczba cech** może uzasadniać analizę korelacji, redukcję wymiarowości lub regularizację.
- **Wiele duplikatów lub niemal identycznych próbek** wymaga sprawdzenia, czy nie doprowadzą do przecieku informacji między treningiem a testem.

W augmentacji danych należy również uwzględnić podział walidacyjny. Augmentacje losowe stosuje się zwykle podczas treningu, natomiast walidacja i test powinny korzystać z ustalonego, powtarzalnego przetwarzania. Transformacje muszą zachowywać semantykę etykiet: na przykład odbicie obrazu nie zawsze jest poprawne, jeśli zmienia znaczenie klasy, a odwrócenie kolejności w szeregu czasowym może zniszczyć informację o kierunku zmian.

4 Zadanie na dziś: raport EDA i plan walidacji

Proszę przygotować krótką notatkę techniczną dotyczącą własnego projektu uczenia głębokiego. Raport powinien zawierać:

1. **Opis zbioru danych:** modalność, źródło, liczba próbek, liczba klas lub charakter zmiennej docelowej, rozmiar pojedynczej próbki oraz kształt tensora wejściowego.
2. **Analizę rozkładu etykiet:** tabela liczebności klas, wykres rozkładu oraz wskazanie ewentualnej nierównowagi.
3. **Analizę jakości danych:** liczba braków, niepoprawnych rekordów, duplikatów i próbek nietypowych. Należy opisać sposób ich weryfikacji i decyzje dotyczące ewentualnego usunięcia lub korekty.
4. **Wizualizację danych:** przykładowe próbki surowe i po przetwarzaniu oraz co najmniej jedną analizę rozkładu cech. W miarę możliwości należy wykonać wizualizację PCA, t-SNE lub UMAP na danych albo embeddingach.

5. **Strategię walidacji:** wybór holdout lub CV, uzasadnienie liczby foldów albo proporcji podziału oraz informację, czy konieczny jest podział stratyfikowany, grupowy lub chronologiczny.
6. **Zabezpieczenie przed przeciekiem danych:** wskazanie, na którym zbiorze będą dopasowywane skalery, imputery, selekcja cech i pozostałe transformacje.
7. **Plan oceny modelu:** wybór metryk uzasadniony charakterem zadania, np. accuracy i macro F1 w klasyfikacji, MAE/RMSE w regresji, IoU/Dice w segmentacji albo odpowiednie metryki jakości generowania.
8. **Wnioski projektowe:** co wyniki EDA oznaczają dla wyboru architektury, strategii treningu, augmentacji, doboru funkcji straty i oceny generalizacji.

Raport ma zawierać nie tylko wykresy, ale również krótką interpretację wyników i uzasadnienie najważniejszych decyzji metodologicznych.