Uzasadnienie strategii budowy modelu

1. Problem i dane

- **Zadanie:** klasyfikacja. Model dostaje 5-sekundowe nagranie i zwraca jedną z 50 klas, np. pies, deszcz albo syrena.
- **Dane:** zbiór ESC-50, 2000 nagrań (40 na klasę). Podział według oficjalnych foldów:
    - foldy 1–3: trening (1200 nagrań),
    - fold 4: walidacja (400),
    - fold 5: test (400).
- **Wejście modelu:** nagranie przepróbkowane do 16 kHz, czyli 80 000 próbek.
- **Wyjście modelu:** 50 wyników, po jednym na klasę (`[B, 50]`).
- **Ocena:**
    - accuracy i F1 (macro),
    - macierz pomyłek,
    - na koniec 5-krotna walidacja krzyżowa.

2. Strategia i rozważona alternatywa

Wybór: uczenie od podstaw (from scratch) obu modeli, z losową inicjalizacją wszystkich parametrów.

Rozważona alternatywa: fine-tuning gotowego modelu wytrenowanego na dużym zbiorze dźwięków (np. PANNs CNN14, trenowany na AudioSet). Przy małym zbiorze zwykle daje wyższą dokładność.

Dlaczego od podstaw:

1. Pytanie projektu brzmi: *która architektura lepiej rozpoznaje dźwięki: CNN na spektrogramie czy GRU na surowym sygnale?* Uczciwe porównanie wymaga, żeby oba modele startowały z tego samego punktu. Gotowa sieć przyniosłaby wiedzę z milionów innych nagrań, więc porównywalibyśmy wtedy zbiory danych, a nie architektury.
2. Dla architektury 1D-CNN + GRU na surowym sygnale nie ma popularnego gotowego modelu do dostrojenia.
3. Literatura podaje wyniki dla modeli trenowanych tylko na ESC-50, więc możemy się do nich bezpośrednio porównać.
4. Chcemy samodzielnie zaprojektować warstwy.

Model generatywny nie dotyczy naszego zadania, bo przypisujemy etykiety, a nie tworzymy nowych nagrań.

Fine-tuning zostaje możliwym rozszerzeniem: jeśli wystarczy czasu, dodamy trzeci model referencyjny.

3. Rodzina i nazwa architektury

Obie sieci są **zaprojektowane przez nas**. Każda ma ok. 0,4 mln parametrów.

	Model 1	**Model 2**
Rodzina	CNN 2D	CRNN: 1D-CNN + GRU
Nazwa	CNN w stylu VGG, 4 bloki konwolucyjne	3 bloki Conv1d + dwukierunkowy GRU (2 warstwy)
Wejście	log-mel-spektrogram `[B, 1, 128, 501]`	surowy sygnał `[B, 1, 80000]`
Dlaczego ta rodzina	spektrogram to „obraz” dźwięku, a CNN wykrywa w nim lokalne wzorce (tony, impulsy)	konwolucje 1D skracają sygnał do 250 kroków, a GRU czyta je po kolei jak sekwencję w czasie

Obie rodziny są zgodne z zaleceniem z materiałów: CNN dla lokalnych wzorców, 1D-CNN i sieci rekurencyjne dla sygnałów.

4. Ograniczenia danych i sprzętu

Dane:

- Tylko 24 nagrania treningowe na klasę, więc łatwo o przeuczenie. Stosujemy augmentację, dropout, weight decay, Early Stopping i małe modele.
- Część nagrań jest dopełniona ciszą zależnie od klasy (wynik EDA). Przeciwdziała temu losowe przesuwanie w czasie.

Sprzęt:

- Laptop z kartą RTX 5060 (8 GB pamięci) i 16 GB RAM.
- Modele muszą być małe; trening zajmie szacunkowo poniżej 2 GB pamięci karty.
- Cały zbiór po przepróbkowaniu (ok. 0,6 GB) mieści się w RAM.
- Ograniczony czas obliczeń to także powód, dla którego walidację krzyżową wykonujemy tylko raz, dla ostatecznych modeli.