Raport z pogłębionej analizy danych (EDA)

1. Charakterystyka zbioru

Modalność	dźwięk
Źródło	ESC-50 (https://github.com/karolpiczak/ESC-50)
Liczebność	2000 nagrań
Zmienna docelowa	klasa: 50 klas w 5 grupach (zwierzęta, natura, ludzie, dom, miasto)
Jedna próbka	5 s, 44,1 kHz, mono, czyli tensor [C, T] = [1, 220 500]
Po przetworzeniu	16 kHz, czyli [1, 80 000]; spektrogram [1, 128, 501]
Metadane	numer foldu (1–5), nagranie źródłowe (src_file), ujęcie (take)

2. Rozkład etykiet

Rozkład klas

- **Każda klasa ma 40 nagrań (2%)**, więc nie ma klas dominujących ani rzadkich.
- Nie ma brakujących etykiet ani niespójnych nazw.
- **W podgrupach (foldach)** każda klasa ma po 8 nagrań w każdym foldzie, więc żaden fold nie jest zdominowany przez wybrane klasy.
- **Niezależnych źródeł jest mniej niż nagrań.** Z jednego nagrania źródłowego autorzy często wycięli kilka fragmentów. Oficjalne foldy trzymają takie fragmenty razem, więc nie trafiają jednocześnie do treningu i testu.
- **Klasy podobne**, które model może mylić: kura i kogut, tykanie zegara i budzik, deszcz i fale, silnik i pociąg. Dwie pierwsze pary mają nawet wspólne nagrania źródłowe.

3. Przestrzeń cech

Jak przygotowano wykres:

- **Punkt na wykresie:** jedno nagranie.
- **Reprezentacja:** 40 cech MFCC, czyli średnia i odchylenie 20 współczynników.
- **Standaryzacja cech:** skaler dopasowany tylko do zbioru treningowego.
- **Parametry rzutowania:**
    - PCA,
    - t-SNE: perplexity 30, ziarno 0,
    - UMAP: n_neighbors 15, ziarno 0.
- **Kolory:** 5 grup klas, w każdym panelu podświetlona jedna grupa.

Obserwacje:

- **PCA:** grupy są wymieszane.
- **t-SNE i UMAP:** każda grupa ma „swój" obszar, ale grupy mocno na siebie zachodzą.
- Widać małe, zwarte skupiska po kilka punktów.

4. Dane

Problem	Jak sprawdziliśmy	Wynik	Decyzja
Uszkodzone pliki	próba odczytu każdego pliku	0	—
Braki, NaN, nieskończoności	kontrola wartości próbek	0	—
Niezgodny format	częstotliwość, kanały, długość	0, wszystkie są jednakowe	—
Duplikaty	suma kontrolna (MD5)	0	—
Wspólne źródło w różnych zbiorach	kolumna src_file	2 nagrania walidacja–test, 0 z treningiem	zostawiamy oficjalne foldy
Dopełnienie ciszą	ciąg zer > 1 s	334 (17%), zależnie od klasy	zostawiamy; losowe przesunięcie w czasie i szum w augmentacji
Przesterowanie / bardzo ciche	poziom próbek	195 / 7	zostawiamy; normalizacja głośności
Obserwacje odstające	Isolation Forest na cechach MFCC + odsłuch	142 wskazane	zostawiamy; odsłuchane przykłady mają poprawne etykiety

Podejrzane etykiety	odsłuch najbardziej nietypowych	0 błędów	—

Najbardziej nietypowe okazały się bardzo głośne syreny i ciche nagrania zwierząt. To **rzadkie, ale poprawne przypadki**, a nie błędy, dlatego **nie usunęliśmy żadnego nagrania**.

5. Wnioski

Co wynika wprost z danych:

- zbiór jest technicznie czysty i idealnie zrównoważony;
- przykładów jest mało: 24 nagrania treningowe na klasę.

Co sugerują wykresy: proste cechy MFCC nie rozdzielają klas, więc potrzebny jest model, który widzi zmiany dźwięku w czasie i częstotliwości.

Hipoteza do sprawdzenia: model może uczyć się ilości ciszy albo głośności zamiast samego dźwięku. Sprawdzimy to metodami wyjaśnialności (XAI).