Akademia Tarnowska
Wydział Nauk Technicznych
Katedra Informatyki
Dr inż. Marcin Skobel

Sieci neuronowe i uczenie głębokie: Projekt
Zajęcia projektowe: Pogłębiona analiza eksploracyjna danych (EDA)

Streszczenie

Celem zajęć jest przeprowadzenie pogłębionej analizy eksploracyjnej zbioru danych wykorzystywanego w projekcie uczenia maszynowego lub uczenia głębokiego. Analiza obejmuje rozkład etykiet, liczebność przykładów, wymiarowość i strukturę danych, wizualizację przestrzeni cech z wykorzystaniem metod redukcji wymiarowości, takich jak t-SNE i UMAP, oraz identyfikację próbek uszkodzonych lub nietypowych. Szczególna uwaga zostanie poświęcona interpretacji wyników i odróżnianiu rzeczywistych obserwacji odstających od błędów pomiaru, przetwarzania lub etykietowania.

1 Cel i zakres pogłębionej analizy eksploracyjnej

Analiza eksploracyjna danych (*Exploratory Data Analysis, EDA*) ma na celu poznanie struktury zbioru przed rozpoczęciem właściwego treningu modelu. Nie polega wyłącznie na wygenerowaniu kilku wykresów. Powinna prowadzić do rozpoznania właściwości danych, ich ograniczeń, problemów jakościowych oraz zależności, które mogą mieć znaczenie dla dalszego projektowania eksperymentu.

W ramach EDA należy odpowiedzieć między innymi na następujące pytania:

- Ile przykładów zawiera zbiór i jak są one rozłożone pomiędzy klasy?
- Czy liczba cech, kanałów, wymiarów lub długość sekwencji jest odpowiednia do planowanego zadania?
- Czy próbki tworzą widoczne skupiska i czy odpowiadają one przypisanym etykietom?
- Czy występują braki, duplikaty, uszkodzone rekordy albo obserwacje znacząco różniące się od pozostałych?
- Czy nietypowe przykłady są błędami, czy mogą reprezentować rzadkie, ale poprawne przypadki?

Analiza powinna łączyć podsumowania liczbowe, wizualizacje oraz kontrolę wybranych próbek. W przypadku danych obrazowych, dźwiękowych i wideo sama analiza statystyczna nie zastępuje oglądania lub odsłuchu rzeczywistych przykładów.

2 Analiza rozkładu etykiet

2.1 Liczebność i udział klas

W zadaniach klasyfikacji pierwszym krokiem jest sprawdzenie liczby występujących klas oraz liczby przykładów przypisanych do każdej z nich. Dla klasy c udział procentowy można zapisać jako

$p(c) = \frac{n_c}{N} \cdot 100\%$, gdzie n_c oznacza liczbę przykładów klasy c, a N – całkowitą liczbę próbek w zbiorze.

Należy zwrócić uwagę na:

- liczbę klas i ich liczebność;
- udział procentowy poszczególnych etykiet;
- klasę dominującą oraz klasy reprezentowane przez niewielką liczbę próbek;
- etykiety brakujące, nieznane lub zapisane w niespójny sposób;
- możliwe pomyłki etykietowania i klasy o bardzo podobnym znaczeniu.

Sama liczba przykładów nie zawsze opisuje rzeczywistą różnorodność danych. Duża liczebność klasy może wynikać z wielokrotnego zapisania niemal identycznych próbek, na przykład kolejnych klatek tego samego filmu albo nakładających się fragmentów jednego sygnału. Warto zatem uwzględnić także liczbę niezależnych źródeł, osób, sesji lub urządzeń.

2.2 Nierównowaga klas i jej interpretacja

Nierównowaga klas występuje wtedy, gdy poszczególne etykiety są reprezentowane przez znacząco różne liczby przykładów. Może ona powodować, że model będzie częściej przewidywał klasę dominującą, nawet jeżeli rozpoznawanie klas rzadkich pozostanie słabe.

Wizualizacja rozkładu etykiet powinna umożliwiać porównanie zarówno liczebności bezwzględnych, jak i udziałów procentowych. W przypadku wielu klas przydatne może być uporządkowanie słupków od klasy najliczniejszej do najrzadszej.

Warto również sprawdzić rozkład etykiet w podgrupach danych, np.:

- według osoby, urządzenia, lokalizacji lub sesji pomiarowej;
- według czasu pozyskania próbki;
- według źródła danych lub sposobu ich rejestracji;
- według dodatkowych kategorii opisujących warunki pomiaru.

Jeżeli w jednej grupie występują niemal wyłącznie wybrane klasy, model może nauczyć się rozpoznawać źródło danych zamiast właściwej cechy zadania. Takie zależności należy odnotować przed rozpoczęciem treningu.

2.3 Rozkład zmiennej docelowej w innych zadaniach

W regresji należy przeanalizować rozkład wartości zmiennej docelowej, jej zakres, medianę, kwartyle oraz wartości skrajne. Warto sprawdzić, czy obserwacje koncentrują się w wąskim przedziale, czy też występują rzadkie zakresy wartości, które mogą być trudne do przewidywania.

W zadaniach wieloetykietowych należy analizować częstość każdej etykiety niezależnie, a także współwystępowanie etykiet. W zadaniach generatywnych istotna jest różnorodność przykładów i sprawdzenie, czy określone typy danych nie są nadmiernie reprezentowane.

3 Analiza wymiarowości i struktury danych

3.1 Liczba próbek, cech i wymiarów

Podstawowy opis zbioru powinien uwzględniać liczbę przykładów N, liczbę cech F oraz sposób reprezentacji pojedynczej próbki. W danych tabelarycznych często wystarczy macierz:

$$X \in \mathbb{R}^{N \times F},$$

gdzie wiersze odpowiadają obserwacjom, a kolumny cechom. W danych o innej modalności reprezentacja może być wielowymiarowym tensorem.

Modalność	**Przykładowy kształt**	**Elementy do sprawdzenia**
Dane tabelaryczne	$[N, F]$	Liczba cech, typy zmiennych, zakresy wartości i braki danych.
Obrazy	$[N, C, H, W]$	Liczba kanałów, rozdzielczość, proporcje i format pikseli.
Audio / sygnały	$[N, C, T]$ lub $[N, F, T]$	Liczba kanałów, częstotliwość próbkowania i długość sygnału.
Tekst	$[N, L]$ lub $[N, L, D]$	Długość sekwencji, tokenizacja, padding i maski.
Szeregi czasowe	$[N, T, F]$	Liczba kroków, liczba zmiennych i częstotliwość obserwacji.
Wideo	$[N, T, C, H, W]$	Liczba klatek, FPS, rozdzielczość i długość nagrania.

Symbole oznaczają: N – liczbę próbek, F – liczbę cech, C – liczbę kanałów, H i W – wysokość i szerokość obrazu, T – liczbę kroków czasowych, L – długość sekwencji, a D – wymiar reprezentacji.

3.2 Kontrola cech i ich zmienności

W danych tabelarycznych należy sprawdzić typ każdej zmiennej, liczbę wartości unikalnych, zakres, średnią, odchylenie standardowe oraz kwartyle. Szczególnej uwagi wymagają cechy:

- stałe lub prawie stałe, które nie wnoszą istotnej informacji;
- zawierające bardzo dużo brakujących wartości;
- zapisane w niezgodnych jednostkach lub skalach;
- silnie skorelowane z innymi zmiennymi;
- zawierające wartości niemożliwe z punktu widzenia dziedziny.

Macierz korelacji może pomóc w rozpoznaniu zależności pomiędzy zmiennymi liczbowymi, natomiast histogramy i wykresy pudełkowe pozwalają ocenić kształt rozkładów oraz obecność obserwacji skrajnych. W przypadku danych wielowymiarowych należy pamiętać, że pojedyncze podsumowania każdej cechy nie opisują wszystkich zależności pomiędzy wymiarami.

Dla obrazów, sygnałów, tekstu i wideo kontrola wymiarowości obejmuje również zgodność kształtów próbek, długości, liczby kanałów i sposobu kodowania danych. Próbki o różnych rozmiarach mogą wymagać osobnego traktowania, dopełniania lub przycinania, ale decyzja ta powinna wynikać z charakteru zadania.

3.3 Wymiarowość a liczebność zbioru

Duża liczba cech w stosunku do liczby niezależnych próbek może utrudniać analizę i zwiększać ryzyko dopasowania modelu do przypadkowych zależności. Wysoka wymiarowość może także powodować, że odległości pomiędzy obserwacjami stają się mniej intuicyjne, a przestrzeń danych jest słabo wypełniona.

Przy interpretacji należy rozróżnić:

- **wymiar wejściowy** – liczbę wartości opisujących próbkę;
- **wymiar reprezentacji** – długość wektora cech lub osadzenia (*embedding*);
- **wymiar wizualizacji** – najczęściej dwa lub trzy wymiary uzyskane po redukcji wymiarowości.

Zmniejszenie wymiaru na potrzeby wykresu nie oznacza, że oryginalne dane miały małą złożoność. Rzutowanie do 2D lub 3D jest uproszczeniem, które może zachowywać tylko wybrane właściwości pierwotnej przestrzeni.

4 Wizualizacja przestrzeni cech

4.1 Cel wizualizacji

Wizualizacja przestrzeni cech pomaga ocenić podobieństwo próbek, możliwe skupiska, nakładanie się klas oraz występowanie obserwacji oddalonych od pozostałych. W przypadku wielu cech nie można bezpośrednio przedstawić danych na klasycznym wykresie dwuwymiarowym. Stosuje się więc metody redukcji wymiarowości, które odwzorowują próbki do przestrzeni 2D lub 3D.

Przed wykonaniem wizualizacji należy określić, co stanowi punkt na wykresie. Może to być pojedyncza obserwacja tabelaryczna, obraz, fragment sygnału, dokument, klatka wideo lub wektor reprezentujący próbkę. W przypadku danych złożonych często wykorzystuje się reprezentacje wyznaczone przez wcześniej wytrenowany model.

4.2 Reprezentacja próbek i embeddingi

Embedding jest wektorowym opisem próbki w przestrzeni cech. Może pochodzić bezpośrednio z danych, z ręcznie przygotowanego zestawu cech albo z warstwy modelu neuronowego. Wektory takie można następnie analizować metodami redukcji wymiarowości.

Wybór reprezentacji ma istotny wpływ na uzyskany wykres. Jeżeli embedding nie koduje informacji ważnych dla rozpatrywanego zadania, widoczne skupiska mogą odzwierciedlać inne właściwości danych, na przykład tło obrazu, warunki nagrania lub długość dokumentu.

4.3 Metoda t-SNE

t-distributed Stochastic Neighbor Embedding (t-SNE) jest nieliniową metodą redukcji wymiarowości, której celem jest zachowanie lokalnych relacji sąsiedztwa. W wyniku działania algorytmu próbki podobne w przestrzeni wejściowej powinny mieć tendencję do znajdowania się blisko siebie na mapie o mniejszej liczbie wymiarów.

Wizualizacja t-SNE bywa użyteczna do obserwowania lokalnych skupisk, jednak wymaga ostrożnej interpretacji:

- odległości pomiędzy odległymi skupiskami nie są wiarygodną miarą globalnego podobieństwa;
- wielkość i kształt skupisk mogą zależeć od parametrów algorytmu;
- wynik może zmieniać się przy zmianie inicjalizacji lub ustawień obliczeń;
- widoczne rozdzielenie etykiet nie stanowi samo w sobie dowodu, że klasy są łatwe do rozpoznania.

Do najważniejszych ustawień należą m.in. liczba sąsiadów uwzględnianych w lokalnej strukturze (*perplexity*), tempo uczenia oraz sposób inicjalizacji. Parametry powinny być dobierane świadomie, a uzyskany obraz interpretowany w odniesieniu do danych wejściowych.

4.4 Metoda UMAP

Uniform Manifold Approximation and Projection (UMAP) jest nieliniową metodą redukcji wymiarowości wykorzystywaną do wizualizacji i analizy struktury danych. W praktyce pozwala przedstawiać próbki w dwóch lub trzech wymiarach, często zachowując istotne relacje lokalnego sąsiedztwa.

Na wynik UMAP wpływają między innymi:

- liczba sąsiadów (*n_neighbors*), która wpływa na zakres struktury uwzględnianej podczas tworzenia odwzorowania;
- minimalna odległość punktów (*min_dist*), wpływająca na zagęszczenie punktów w przestrzeni wynikowej;
- metryka odległości oraz sposób inicjalizacji;
- losowość obliczeń i przyjęte ziarno generatora.

Podobnie jak w przypadku t-SNE, nie należy traktować wykresu UMAP jako dokładnej mapy odległości w oryginalnej przestrzeni cech. Wnioski powinny być sprawdzane również z wykorzystaniem statystyk, przykładów źródłowych i innych metod analizy.

4.5 Porównanie i interpretacja map 2D

Właściwość	t-SNE	UMAP
Główne zastosowanie	Eksponowanie lokalnych sąsiedztw i skupisk.	Wizualizacja lokalnej struktury i relacji pomiędzy próbkami.
Parametry	m.in. perplexity, learning rate, inicjalizacja.	m.in. n_neighbors, min_dist, metryka.
Interpretacja	Ostrożnie oceniać odległości między odległymi skupiskami.	Nie utożsamiać odległości na mapie z pełną geometrią danych.
Powtarzalność	Może zależeć od inicjalizacji i ustawień.	Może zależeć od ziarna losowości i ustawień.

W praktyce warto porównać kilka wariantów parametrów i sprawdzić, czy najważniejsze obserwacje pozostają podobne. Na mapie punkty można oznaczyć kolorami zgodnie z etykietami, źródłem danych lub wybraną cechą. Należy jednak unikać nadmiernego przeładowania wykresu, zwłaszcza gdy liczba próbek jest duża.

4.6 Zasady poprawnego przygotowania wizualizacji

Przed zastosowaniem t-SNE lub UMAP należy rozważyć przygotowanie reprezentacji wejściowej. W szczególności:

- sprawdzić braki danych i niepoprawne wartości;
- uwzględnić różne skale cech, jeżeli mogą wpływać na odległości;
- określić, czy wizualizacja dotyczy surowych cech, czy embeddingów;
- zapisać wykorzystane parametry oraz ziarno losowości;
- zachować powiązanie punktów na wykresie z identyfikatorami próbek.

Wizualizacja całego bardzo dużego zbioru może wymagać ograniczenia liczby punktów albo zastosowania wcześniejszej redukcji wymiarowości. Sposób wyboru próbek powinien być opisany, aby nie ukrywać klas rzadkich lub obserwacji nietypowych.

5 Identyfikacja próbek uszkodzonych i nietypowych

5.1 Błędy techniczne i problemy jakości danych

Próbka uszkodzona nie musi być jednocześnie obserwacją odstającą w sensie statystycznym. Może być niemożliwa do odczytania, niekompletna lub niezgodna z oczekiwanym formatem. Kontrola jakości powinna objąć:

- **Braki danych:** wartości puste, NaN, brakujące kanały albo niekompletne sekwencje.
- **Wartości niepoprawne:** nieskończoności, wartości poza dopuszczalnym zakresem, niezgodne typy i błędne jednostki.

- **Uszkodzone pliki:** obrazy i nagrania, których nie można odczytać, pliki o zerowej długości lub uszkodzone klatki wideo.
- **Niezgodny format:** różne wymiary obrazów, liczby kanałów, częstotliwości próbkowania lub struktury rekordów.
- **Duplikaty:** powtórzone rekordy, identyczne obrazy lub silnie nakładające się fragmenty sygnałów.
- **Błędne etykiety:** przypisanie próbce klasy niezgodnej z jej rzeczywistą zawartością.

Kontrola powinna obejmować zarówno automatyczne sprawdzenia zbioru, jak i ręczną inspekcję wybranych przykładów. W przypadku obrazów należy obejrzeć pliki, dla nagrań audio wskazany jest odsłuch, a w przypadku szeregów czasowych – analiza przebiegów.

5.2 Obserwacje odstające

Obserwacja odstająca (*outlier*) to próbka, która znacząco różni się od większości danych. Nietypowość może dotyczyć jednej cechy, wielu cech jednocześnie, przebiegu sygnału lub położenia w przestrzeni embeddingów.

Do wstępnego wykrywania takich obserwacji można wykorzystać:

- statystyki opisowe, histogramy i wykresy pudełkowe;
- odległości od najbliższych sąsiadów;
- metody oparte na lokalnej gęstości, np. Local Outlier Factor (LOF);
- algorytm Isolation Forest;
- odległości w przestrzeni cech lub embeddingów.

Wybór metody zależy od rodzaju danych i ich wymiarowości. Metoda wykrywająca wartości skrajne w pojedynczej zmiennej może nie wykryć próbki nietypowej ze względu na kombinację kilku cech. Z kolei odległości w przestrzeni o dużej liczbie wymiarów mogą być trudne do interpretacji.

5.3 Nietypowa próbka czy poprawny przypadek rzadki?

Wynik algorytmu wykrywania anomalii powinien być traktowany jako wskazanie do dalszej weryfikacji, a nie automatyczna decyzja o usunięciu danych. Próbka nietypowa może wynikać z:

- błędu rejestracji, transmisji lub przetwarzania;
- nieprawidłowego oznaczenia etykiety;
- szczególnych warunków pozyskania danych;
- rzadkiego, ale poprawnego przypadku należącego do badanej klasy.

Przed podjęciem decyzji należy sprawdzić próbkę w jej oryginalnej postaci, porównać ją z innymi przykładami tej samej klasy oraz zweryfikować metadane i warunki pozyskania. Usuwanie obserwacji wyłącznie dlatego, że leżą daleko od skupiska na wykresie t-SNE lub UMAP, nie jest wystarczającym uzasadnieniem.

5.4 Dokumentowanie decyzji dotyczących jakości

Dla każdej wykrytej grupy problemów należy odnotować rodzaj nieprawidłowości, liczbę dotkniętych próbek, sposób weryfikacji oraz podjętą decyzję. Warto zachować identyfikatory próbek i umożliwić odtworzenie procesu czyszczenia.

Problem	**Sposób weryfikacji**	**Informacja do raportu**
Brakujące wartości	Podsumowanie braków i kontrola rekordów.	Liczba i udział próbek z brakami.
Uszkodzony plik	Próba odczytu oraz inspekcja zawartości.	Identyfikatory i typ uszkodzenia.
Duplikaty	Porównanie rekordów lub reprezentacji próbek.	Liczba duplikatów i reguła ich rozpoznawania.
Obserwacja odstająca	Analiza statystyczna i kontrola próbki źródłowej.	Metoda wykrywania i wynik weryfikacji.
Podejrzana etykieta	Porównanie treści próbki z opisem klasy.	Przypadki wymagające ponownego oznaczenia.

6 Łączenie wyników EDA

Wyniki poszczególnych etapów należy interpretować łącznie. Nierówny rozkład etykiet może być związany z konkretnym źródłem danych, a próbki nietypowe mogą tworzyć osobne skupisko na mapie embeddingów. Wysoka wymiarowość może utrudniać wykrywanie anomalii, a błędne etykiety mogą powodować pozorne nakładanie się klas.

Podczas formułowania wniosków należy rozróżniać:

- obserwacje bezpośrednio wynikające z danych i podsumowań;
- zależności sugerowane przez wizualizacje;
- hipotezy wymagające dodatkowej weryfikacji;
- decyzje dotyczące korekty, oznaczenia lub wyłączenia próbek.

Wykres t-SNE lub UMAP nie powinien być jedyną podstawą wniosku o jakości zbioru. Interpretację należy zestawić z rozkładami cech, metadanymi i kontrolą przykładów źródłowych. W szczególności nie należy zakładać, że skupiska odpowiadają klasom, dopóki ich znaczenie nie zostanie zweryfikowane.

7 Raport z pogłębionej analizy jakościowej (EDA)

Jeżeli specyfika Twojego projektu na to pozwala, przygotuj skrócony raport z pogłębionej analizy danych, uwzględniając wybrane z poniższych aspektów:

- Charakterystyka zbioru i metadane: Podstawowe parametry danych (modalność, źródło, liczebność, wymiary próbek) oraz charakter zmiennej docelowej.

- Analiza rozkładów i struktur: Rozkład etykiet/zmiennej docelowej (w tym klasy dominujące/rzadkie) lub specyfika rozkładu cech ciągłych/sekwencji.
- Analiza przestrzeni cech (opcjonalnie): Jeśli ma to uzasadnienie, wstępna eksploracja cech lub wizualizacja (np. t-SNE/UMAP).
- Pamiętaj: Skupiska na wykresach nie są dowodem na poprawność klas – wymagają one weryfikacji w zestawieniu z metadanymi i źródłowymi przykładami.
- Higiena i czystość danych: Identyfikacja anomalii, braków, uszkodzonych plików, duplikatów oraz próbek odstających (outliers) wraz z decyzją o ich obsłudze.
- Wnioski i rekomendacje: Podsumowanie ograniczeń jakościowych zbioru oraz ich potencjalnego wpływu na budowę i trening modelu.

Forma raportu: Krótki dokument (lub sekcja w notebooku) zawierający kluczowe wykresy/tabele wraz z ich zwięzłą interpretacją – ze szczególnym naciskiem na wnioski praktyczne dla dalszego przebiegu projektu.